

신경망 모델 보고서

제출일: 25.06.28

제출인: 서윤철

개요

- 서론
- 본론
- 결론
- 고찰

서론

내용

- 신경망 모델 이미지 처리
- 다층 퍼셉트론(MLP)
- 다층 퍼셉트론(Multilayer Perceptron, MLP) 기반의 완전 연결 신경망(Fully Connected Neural Network)
- CIFAR10 dataset 시뮬레이션

목표

- 어떤 모델이 이미지 처리에 적합한지 확인하기
- 하이퍼 파라미터의 여러 가능성을 점검해보고 최적의 설정 찾아보기

수정할 하이퍼 파라미터

- 학습 횟수: epoch
- 배치 크기: batch_size
- 검증용 데이터: validation_split

최적의 설정

- 훈련 속도와 성능 간의 균형 유지
- Training Accuracy와 Validation Accuracy 모두를 높임
- Underfitting 또는 Overfitting 방지

하이퍼 파라미터 조정 시 주의사항

- val_accuracy가 줄어들기 시작하는 지점을 기준으로 최적의 epoch 선택
- epochs 너무 크면 overfitting
- 작은 배치는 더 정확하지만 느림
- 큰 배치 빠르지만 덜 일반화 가능성 있음
- validation_split은 일반적으로 0.2 사용, but 데이터가 충분하므로 0.1 ~ 0.3 사이 실험 가능

전략

- 두가지 모델에 대해서 각각 하이퍼 파라미터 값에 따른 9가지 케이스를 시뮬레이션하여 결과를 확인한 뒤, 예상되는 최적의 케이스를 도출

본론

데이터 전처리

- 이미지를 1차원 벡터로 펼치고 0~1 사이로 정규화

모델

- MLP(다층 퍼셉트론)

층	특징	역할
입력층	입력: 32*32*3, 출력: 128개의 뉴런 (ReLU 활성화)	입력을 비선형적으로 변환
은닉층1	뉴런 수: 128 → 64 더 추상적인 특징 학습	더 추상적인 특징을 학습
은닉층2	뉴런 수: 64 → 32 더욱 더 추상적인 특징 학습	더욱 더 추상적인 특징을 학습
출력층	10개 클래스 확률 출력 (softmax 활성화)	가장 높은 값의 인덱스 = 예측 결과

model.compile	특징
loss	정수형 레이블용 다중 분류 손실 함수 (sparse_categorical_crossentropy)
optimizer	sgd (확률적 경사하강법)
accuracy	정확도를 평가 지표로 사용


- MLP 기반의 완전 연결 신경망 (Fully Connected Neural Network, FCNN)

층	특징	역할
입력층	입력: 32*32*3, 출력: 128개의 뉴런 (ReLU 활성화)	입력을 비선형적으로 변환
은닉층	뉴런 수: 128 → 64 더 추상적인 특징 학습	더 추상적인 특징을 학습
드롭아웃	학습 중 랜덤하게 뉴런 절반을 끄(50%, 과적합 방지)	학습 안정 + 일반화 성능이 좋아짐
출력층	10개 클래스 확률 출력 (softmax 활성화)	가장 높은 값의 인덱스 = 예측 결과

model.compile	특징
loss	정수형 레이블용 다중 분류 손실 함수 (sparse_categorical_crossentropy)
optimizer	sgd (확률적 경사하강법)
accuracy	정확도를 평가 지표로 사용


신경망 모델 이미지(MNIST) 처리

- MLP (epoch=30, batch_size=64, validation_split=0.2)



=> valid_accuracy: 0.9710, valid_loss: 0.1022

- FCNN (epoch=30, batch_size=64, validation_split=0.2)





=> valid_accuracy: 0.9643, valid_loss: 0.1180

: 단순한 이미지인 MNIST를 처리했을 경우, 동일한 하이퍼 파라미터 조건에서 일반 MLP와 MLP기반의 FCNN의 성능은 거의 비슷하다.



신경망 모델 이미지(CIFAR-10 dataset) 처리

- MLP (epoch=30, batch_size=64, validation_split=0.2)



=> valid_accuracy: 0.4716, valid_loss: 1.5019

- 다층 퍼셉트론(MLP) 기반의 완전 연결 신경망(Fully Connected Neural Network, FCNN) (epoch=30, batch_size=64, validation_split=0.2)




=> valid_accuracy: 0.4647, valid_loss: 1.5228

: MNIST보다 복잡한 이미지인 CIFAR10을 처리했을 경우 accuracy에서 큰 차이를 보이는 것을 확인하였다. 하지만 valid의 결과는 둘의 차이가 미미하다는 것을 확인하였다. 이 원인에 대해 조사한 바에 따르면, 데이터가 충분히 많아야 MLP기반의 FCNN의 장점이 발휘되며 FCNN이더라도 layer의 개수가 적더라도 일반적인 MLP와 실질적인 차이가 나지 않을 수 있다고 한다. 또한 최적화(optimizer), learning rate, dropout 등 하이퍼 파라미터가 충분히 튜닝되지 않았다면 성능 격차가 작을 가능성도 존재한다. 그러므로 하이퍼 파라미터 조정값인 batch_size, epochs, validation_split만을 제어하여 최적의 조건을 찾기 위해서는 두 모델 간의 유의미한 차이가 존재해야 한다고 생각했다. 그리하여 강의 자료에 나와있는 조건을 수정하여 실습을 진행하고자 했지만, 그 또한 유의미한 차이가 발생하지 않아 그냥 MLP 기반 FCNN과 일반적인 MLP의 하이퍼 파라미터 값을 조정하여 실습하겠다.


MLP

- epochs=100, batch_size=64, validation_split=0.2




=> valid_accuracy: 0.5125, valid_loss: 1.5573

- epochs=150, batch_size=64, validation_split=0.2




=> valid_accuracy: 0.4942, valid_loss: 1.9596

- epochs=30, batch_size=32, validation_split=0.2




=> valid_accuracy: 0.4984, valid_loss: 1.4503

- epochs=100, batch_size=32, validation_split=0.2




=> valid_accuracy: 0.5040, valid_loss: 1.8660

- epochs=150, batch_size=32, validation_split=0.2




=> valid_accuracy: 0.4933, valid_loss: 2.3901

- epochs=30, batch_size=16, validation_split=0.2




=> valid_accuracy: 0.4970, valid_loss: 1.4650

- epochs=100, batch_size=16, validation_split=0.2



=> valid_accuracy: 0.4900, valid_loss: 1.8997


- epochs=150, batch_size=16, validation_split=0.2



=> valid_accuracy: 0.4913, valid_loss: 2.5780


MLP 기반 FCNN

- epochs=100, batch_size=64, validation_split=0.2




=> valid_accuracy: 0.5046, valid_loss: 1.4420

- epochs=150, batch_size=64, validation_split=0.2




=> valid_accuracy: 0.5133, valid_loss: 1.4615

- epochs=30, batch_size=32, validation_split=0.2




=> valid_accuracy: 0.4675, valid_loss: 1.4865

- epochs=100, batch_size=32, validation_split=0.2




=> valid_accuracy: 0.5101, valid_loss: 1.4530

- epochs=150, batch_size=32, validation_split=0.2




=> valid_accuracy: 0.5114, valid_loss: 1.5196

- epochs=30, batch_size=16, validation_split=0.2




=> valid_accuracy: 0.4869, valid_loss: 1.4455

- epochs=100, batch_size=16, validation_split=0.2



=> valid_accuracy: 0.5050, valid_loss: 1.4790

- epochs=150, batch_size=16, validation_split=0.2



=> valid_accuracy: 0.4996, valid_loss: 1.6581

결론

- valid_accuracy

MLP	30	100	150
16	49.70%	49.00%	49.13%
32	49.84%	50.40%	49.33%
64	47.16%	51.25%	49.42%

표의 30, 100, 150 => epochs, 16, 32, 64 => batch_size

MLP기반 FCNN	30	100	150
16	48.69%	50.50%	49.96%
32	46.75%	51.01%	51.14%
64	46.47%	50.46%	51.33%

표의 30, 100, 150 => epochs, 16, 32, 64 => batch_size

- valid_loss

MLP	30	100	150
16	1.4650	1.8997	2.5780
32	1.4503	1.8660	2.3901
64	1.5019	1.5573	1.9596

표의 30, 100, 150 => epochs, 16, 32, 64 => batch_size

MLP기반 FCNN	30	100	150
16	1.4455	1.4790	1.6581
32	1.4865	1.4530	1.5196
64	1.5228	1.4420	1.4615

표의 30, 100, 150 => epochs, 16, 32, 64 => batch_size

: CIFAR-10 이미지를 MLP나 MLP기반의 FCNN 모델로 처리하는 것은 부적합

고찰

MLP, MLP 기반의 FCNN 두 모델을 사용하여 비교적 단순한 이미지인 MNIST를 처리한 결과 각각 97%, 96%로 높은 정확도를 확인하였다. 이는 선형 모델을 사용하여 MNIST를 처리한 정확도와 비교했을 때 크게 향상된 결과이다.

반면, MNIST에 비해 복잡한 CIFAR-10을 처리한 경우, 선형모델과 이번 실습의 두 모델간의 차이가 비교적 미미했다. 세 모델 모두 CIFAR-10을 처리하기엔 역부족이다.

하지만 이번 실습에서는 배치 크기가 클수록 정확도와 손실 측면에서 성능이 향상되는 경향을 확인할 수 있었는데, 이는 이전 실습에서 '작은 배치 크기가 더 좋을 수 있다'는 예상과 상반된 결과였다. 다만, 에포크 수에 따른 성능 변화의 뚜렷한 방향성은 관찰되지 않아 이 부분은 추후 더 정밀한 실험이 필요할 것으로 보인다.

현재 비선형모델, MLP는 CIFAR-10을 처리하기에 적합하지 않다. 현재 모델을 향상시키기 위해 optimizer를 변경하거나 dropout 이외에도 배치 정규화(batch normalization)이라는 추가 기법 등을 사용한다면 성능을 개선시킬 수 있다고 한다. 그렇다하더라도 CIFAR-10을 처리하는 것은 역부족이다.

이러한 한계를 극복하기 위해서는 CNN(Convolutional Neural Network) 기반 모델의 도입이 필요하다. CNN은 이미지의 공간 구조와 지역적 특징(예: 모서리, 윤곽, 패턴 등)을 효과적으로 학습할 수 있도록 설계된 구조이기 때문에, MLP보다 훨씬 적은 파라미터로도 더 높은 성능을 낼 수 있다. 실제로 CIFAR-10과 같은 복잡한 이미지 데이터셋에서는 CNN이 표준처럼 사용되며, 높은 정확도를 안정적으로 달성하고 있다고 한다.

따라서 향후 실습에서는 CNN 모델을 기반으로 실험을 진행하고, 다양한 합성곱 필터 및 풀링, 정규화 기법을 활용하여 CIFAR-10 분류 성능을 보다 효과적으로 향상시킬 수 있을 것으로 기대된다.