




Perceptron



목차

Perceptron

MLP

Deep Learning

Perceptron의 등장

- 인공신경망은 1943년 워렌 맥컬록(Warren McCulloch)과 월터 피츠(Walter Pitts)의 논문에서 시작된 인간의 뇌를 기계적으로 모델링한 최초의 시도
- 이후 1949년, 캐나다의 심리학자 도널드 헵(Donald Hebb)이 뉴런 사이의 연결 강도를 조정할 수 있는 학습 규칙을 발표
- 1957년 프랭크 로젠블라트(Frank Rosenblatt)가 고안한 최초의 인공신경망 모델 중 하나입니다. 이 모델은 데이터를 학습하여 이진 분류를 수행하며 인공지능 연구에 큰 기대를 주었습니다.
- 인공지능(AI)과 딥러닝에서 퍼셉트론(Perceptron)은 중요한 개념
- 본 강의는 퍼셉트론의 기본 개념, 작동 원리 및 한계를 탐구하고, 이러한 한계를 극복하며 현대 딥러닝 발전에 기여한 방식을 다룹니다. 또한, 실습용 파이썬 코드와 시각화 방법을 제공하여 이론과 실제를 연결하는 데 중점을 둡니다.

Perceptron의 등장

The New York Times

NEW NAVY DEVICE LEARNS BY DOING

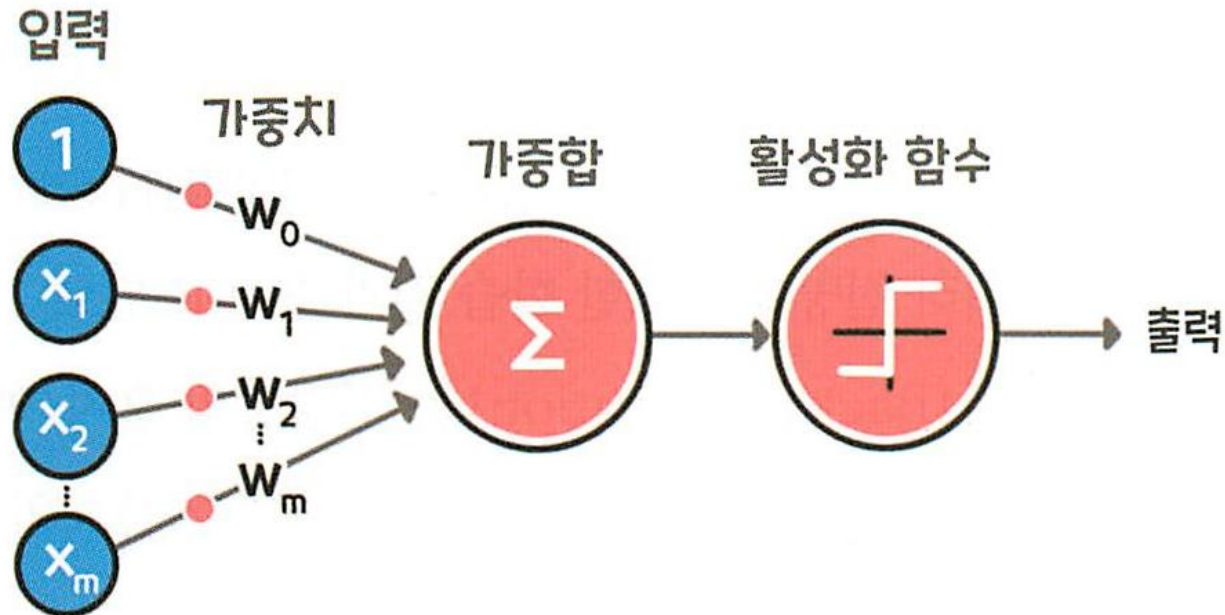
July 8, 1958

"The Navy revealed the embryo of an electronic computer today that it expects will be able to walk, talk, see, write, reproduce itself and be conscious of its existence... Dr. Frank Rosenblatt, a research psychologist at the Cornell Aeronautical Laboratory, Buffalo, said Perceptrons might be fired to the planets as mechanical space explorers"

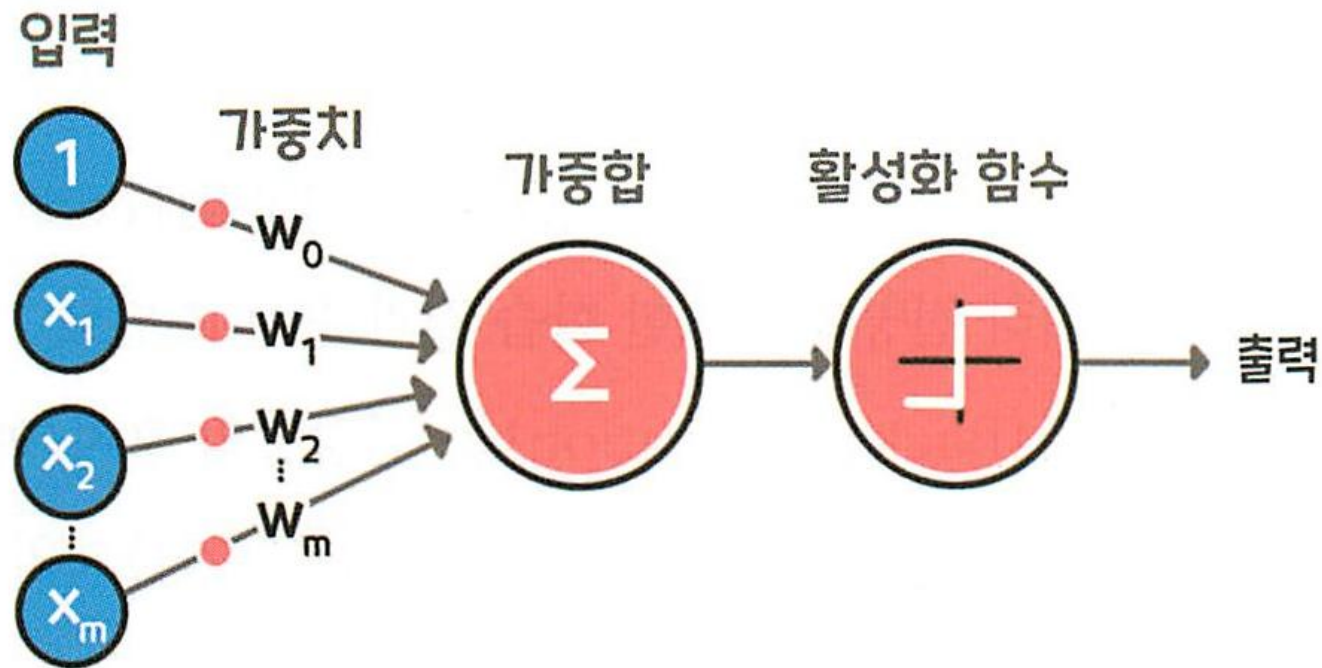
"컴퓨터는 걷고, 말하고, 보고, 쓰고, 재생산하고, 자의식을 갖출 것이다."

Perceptron definition

- 퍼셉트론은 생물학적 뉴런을 수학적으로 모델링한 '인공 뉴런'으로, 여러 입력 신호를 받아 각각의 가중치를 곱한 후 이를 합산해 활성화 함수를 통해 단일 신호를 출력한다.
- 퍼셉트론의 출력은 신호 유무(1 또는 0)로 표현되며, 이진 분류 문제 해결에 효과적이다.
- 입력 신호의 중요성을 나타내는 가중치는 머신러닝의 '학습' 과정에서 조정된다.



Perceptron Structure



- 입력(Input) : AND 또는 OR 연산을 위한 입력 신호
- 가중치(Weight) : 입력 신호에 부여되는 중요도로, 가중치가 크다는 것은 그 입력이 출력을 결정하는 데 큰 역할을 한다는 의미
- 가중합(Weighted Sum) : 입력값과 가중치의 곱을 모두 합한 값
- 활성화 함수(Activation Function) : 어떠한 신호를 입력받아 이를 적절하게 처리하여 출력해 주는 함수로, 가중합이 임계치(Threshold)를 넘어가면 1, 그렇지 않으면 0을 출력함
- 출력(Output) : 최종 결과(분류)



실습

- AND Gate Perceptron
- OR Gate Perceptron
- NAND Gate Perceptron
- XOR Gate Perceptron

단층 Perceptron의 한계점

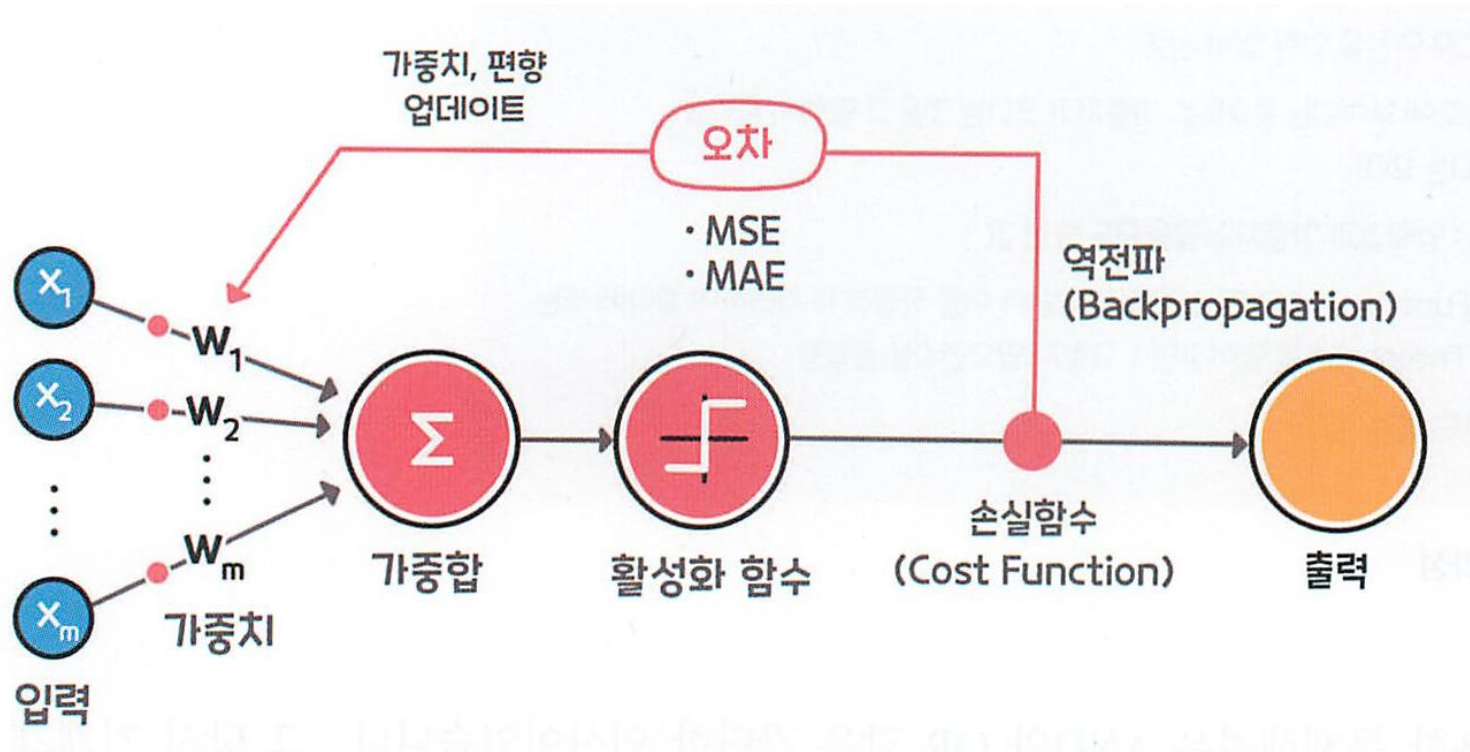
- 단층 퍼셉트론은 XOR 문제처럼 선형적으로 구분되지 않는 데이터뿐 아니라 현실의 복잡한 비선형 데이터를 처리하기 어렵다는 한계가 있다.
- 이진 출력만 가능해 예측의 확률적 신뢰도를 제공하지 못하며, 초기 가중치나 편향 값 설정에 민감해 학습의 안정성이 떨어진다.
- 이러한 제약들이 현실적인 응용을 어렵게 만들어 결국 다층 퍼셉트론과 같은 더 발전된 신경망 모델이 등장하게 되었다.

Multi Layer Perceptron

- 다층 퍼셉트론(MLP)은 단층 퍼셉트론의 한계를 극복하기 위해 등장한 모델로, 입력층과 출력층 사이에 은닉층을 도입하여 복잡한 비선형 패턴을 자동으로 학습한다.
- 이는 특징을 인간이 수동으로 설정하지 않고 네트워크가 스스로 특징을 추출하고 학습(특징 학습)하는 개념으로, 현대 딥러닝의 기반이 된다.
- MLP는 비선형 활성화 함수(시그모이드, ReLU)를 사용하여 연속적이고 복잡한 관계를 모델링
- 오류역전파(Error Backpropagation) 알고리즘을 통해 효율적으로 가중치를 학습한다. 이를 통해 XOR 문제와 같은 비선형 문제를 해결 가능하게 하였으며, 자동화된 표현 학습이 가능한 현대적 신경망 발전의 핵심적 역할을 수행한다.

Backpropagation Process


- 신경망의 오차 (예측값과 실제값의 차이)를 출력층에서부터 입력층으로 거꾸로 전파시켜 각 층(Layer)의 가중치와 편향(Bias)을 업데이트 함.



Backpropagation

- 1974년 폴 웨어보스(Paul Werbos)가 박사과정 논문에서 처음 제안
- 하지만 당시 인공지능망에 대한 실망감이 만연해 외면 받음.
- 1986년 제프리 힌턴(Geoffrey Hinton)이 또 다른 역전파 방법을 고안
- 이 제안 방법으로 XOR 연산 문제뿐만 아니라 더 복잡한 문제로 해결할 수 있음이 증명됨.
- 이 후의 인공지능망 연구는 큰 진전이 있었지만 다음과 같은 이유로 침체기에서 벗어나기는 어려웠음
- 신경망의 깊이가 깊어질수록 원하는 결과를 얻을 수 없음
(기울기 소멸 문제 - Vanishing Gradient / 기울기 발산 문제 - Exploding Gradient)
- 신경망 학습에 최적화된 하이퍼파라미터에 대한 이론적인 근거가 없음

Appendix - 기울기 소멸, 발산 문제



역전파 과정에서 기울기가 소멸되거나 발산되는 문제 발생

Appendix – MSE, MAE

- 회귀모델에서 오차를 계산하는 방법으로는 MSE와 MAE가 많이 사용됨

1. MSE(Mean Squared Error)

- 의미 : 예측값과 실제값의 차이인 오차들의 제곱에 대한 평균
- 수식 :
$$\frac{\sum (\text{예측값} - \text{실제값})^2}{n}$$
- 장점 : 직관적이고 단순함
- 단점 : ① 오류를 제공하기 때문에 1 미만의 오류는 더 작아지고 그 이상의 오류는 더 커지는 값의 왜곡이 발생
② 스케일에 의존적

2. MAE(Mean Absolute Error)


- 의미 : 예측값과 실제값의 차이인 오차들의 절댓값에 대한 평균
- 수식 :
$$\frac{\sum (|\text{예측값} - \text{실제값}|)}{n}$$
- 장점 : 매우 직관적인 지표
- 단점 : 스케일에 의존적

'스케일에 의존적'이란 의미는 다음과 같습니다.
예를 들어 아파트 집값이 10억이고 책값이 2만원임에도 MSE를 적용한 결과가 똑같이 80이 나온다면, 동일한 오차율이 아님에도 불구하고 동일하게 평가되는 현상이 발생합니다.
이를 '스케일에 의존적'이라고 합니다.



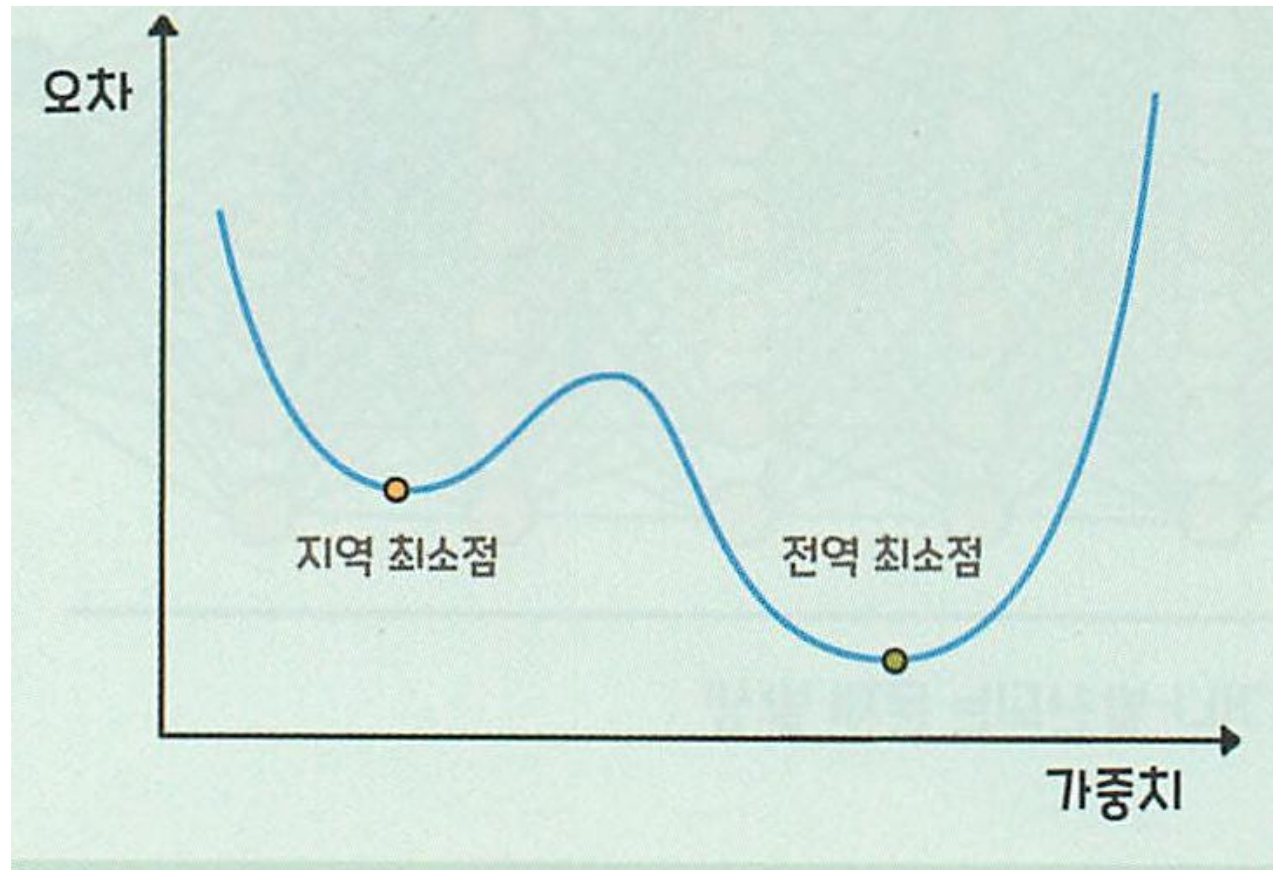
Appendix - 기울기 계산

- 경사 하강법은 오류가 작아지는 방향으로 가중치(w)값을 보정하기 위해 사용함.
- 가중치값을 보정하는 방법은 그래프와 같이 전역 최소점인 접선의 기울기가 0이 되는 지점, 즉 미분값이 0인 점을 찾는 것
- 최초 가중치에서부터 미분을 적용한 뒤 이 미분값이 계속 감소하는 방향으로 순차적으로 가중치값을 업데이트
- 이후 업데이트가 끝나는 전역 최소점에서 가중치값을 반환



Appendix – Local Minimum, Global Minimum

- 손실함수에는 지역 최소점(Local Minimum)과 전역 최소점(Global Minimum)이 있음
- 지역 최소점은 함수 일부 구간의 최소값
- 전역 최소점은 전체 구간의 최소값



Deep Learning

- 2006년, 역전파를 고안했던 제프리 힌턴 교수는 “A fast learning algorithm for deep belief nets” 라는 논문을 제안
- 가중치 초기값을 제대로 설정하면 깊이가 깊은 신경망도 학습이 가능하다는 성과를 보여줌.
- 이것은 신경망을 학습시키기 전에 계층(입력층, 은닉층) 단위의 학습을 거쳐 더 나은 초기값을 얻는 방식인 사전훈련(Pre-training) 방식을 제안한 것임.
- 2007년 벤지오(Bengio)팀이 “Greedy layer-wise training of deep networks”라는 논문을 통해 오토인코더(Auto Encoder)를 사용한 좀 더 간단한 사전훈련 방법을 제안
- 이러한 노력들로 인하여 깊이 있는 신경망에서도 학습이 가능하게 되었음.
- 길고긴 침체기 속에서는 인공신경망(Neural)이라는 용어만 들어가도 논문 채택이 거절당할 정도로 부정적인 인식이 강해서 사람들의 이목을 끌만한 단어가 필요했는데 2006년 부터 Deep Learning이라는 용어가 사용되기 시작함.

Appendix – Autoencoder

- 오토인코더(Autoencoder)는 입력층과 출력층이 동일한 네트워크에 데이터를 입력하여 비지도학습을 하는 것.
- 인코더(Encoder)를 통해 입력 데이터에 대한 특징을 추출
- 디코더(Decoder)를 통해 원본 데이터를 재구성하는 학습을 진행
- 가중치의 좋은 초기값을 얻는 목적으로 이용됨.
- 특히, 데이터 압축때문에 중요성이 부각되는데 영상 데이터 처럼 의미 없는 부분이 많은 데이터는 중요한 부분만 추려낸 후에도, 그 데이터로 원본을 복원할 수 있음.

